Adatbányászat beadandó

A feladat rövid összefoglalása

Adathalmazunk a Free Music Archive (FMA)-ról származik. Különböző zeneszámok tulajdonságait foglalja magában 4 csv fájlon keresztül(tracks.csv, features.csv, genres.csv, echonest.csv). A fájlokat összeköti a *trackid* nevű attribútum.

Feladatunk a zeneszámok műfajának(*genre*) megjósolása volt az adatok alapján. Összesen 163 alműfaj található a fájlokban, amik 16 gyökérműfajba sorolhatók. Végső megoldásunkban mindkét besorolásra építettünk modelleket. Ehhez az alábbi adatbányászati módszereket hívtuk segítségül: Döntési fa, kNN, Random Forest, DBSCAN.

Kezdeti nehézségek

Több nehézségbe is ütköztünk a munkánk során, amikre eleinte egyáltalán nem gondoltunk. Ugyanis a legtöbb időt a megfelelő adathalmaz alkalmazható létrehozása, illetve betöltése vett el.

Először a tracks.csv fájllal kezdtünk el dolgozni, ami kezdetben jónak tűnt, mivel egy-egy szám albumáról, előadójáról és különböző tulajdonságairól is többféle adatot tartalmaz. Azonban nagyon sok benne a karakter típusú attribútum, aminek feldolgozásáról nem volt szó a félév során, időnk pedig nem volt megtanulni. Így ezt az utat elvetettük. (De eddig sok idő eltelt.)

A features.csv fájl viszont nagyon sok számadatot tartalmaz a zeneszámok frekvenciáiról, rezgéséről stb., így ezzel már tudtunk dolgozni. A fájl nagy mérete miatt úgy döntöttünk, hogy a könnyebb kezelhetőség miatt egy rövid python kóddal kb. leharmadoljuk az adatokat, így kaptuk meg az adatb.csv-t:

```
f = open(r"c:\users\dell\Desktop\a\features.csv", "r")

outf = open(r"c:\users\dell\Desktop\a\adatb.csv", "w+")

import random

#az első sort beolvassuk, mivel az attribútum nevekre szükségünk
lesz

first_line = f.readline

#ki is írjuk, a "trackid"-t hozzávéve, mivel az a második sorban
szerepelt

outf.write("trackid;"+ first_line)

f.readline()

#végigmegyünk az adatokon, és ha a random generált (0,3) közé eső
számunk 1, akkor kiírjuk az adott sort

for line in f:

       if random.randint(0, 3) == 1:

              outf.write(line.strip() + "\n")

outf.close()
```

Mivel ez a fájl nem tartalmazott *genre* oszlopot, így nekünk kellett azt létrehozni, ügyelve, hogy minden *trackid*-hoz jól párosítsuk a műfajokat. A tracks.csv-ben szerepeltek a műfajok, így ezt segítségül tudtuk hívni. Egy „szótárt” készítettünk, melyben a *trackid-genre* párokat létrehoztuk (a műfajnak a kódját megadva), majd ezután FKERES függvénnyel hozzárendeltük az adatb.csv-ben minden sorhoz a megfelelő műfajt.

Miután a szótárt elkészítettük, észrevettük, hogy sok sor betűket, furcsa karaktereket tartalmaz. Valószínűleg a baj abból adódott, hogy a csv fájl beolvasásakor tördeléskénk pontosvesszőt használtunk, ami olyan helyeken is szerepelt, ahol nem szerettünk volna tördelni. Így sok, eredetileg egy oszlopba való karaktersorozatot is eltördeltünk külön oszlopokba. Végül a műfaj hozzárendelés után ezt úgy oldottuk meg, hogy az Excel szűrőjét használva ki tudtuk szelektálni a „rossz” sorokat, amikből összesen csak kb. 800 volt. Így ezeket mind töröltük, maradt 25400 adatsorunk.

Volt egy genres.csv fájlunk is, amiben minden *genreid*-hoz meg volt adva a gyökérműfaja(*genre_top*). Mi ezeket is hozzárendeltük az adatb.csv adathalmazunkhoz, így kétféle célváltozóra tudtunk „jósolni”. A továbbiakban jelöljük ezeket Y, illetve Z esetként (a kódjainkban is ezeket a betűket használtuk):

- Y eset: amikor a gyökérműfaj(*genre_top*) a célváltozó; ez 16 műfaj.
- Z eset: amikor az összes lehetséges műfaj(*genre*) a célváltozó; ez 163 műfaj.

Adathalmaz betöltése

Először a Google Drive-ba töltöttük fel az adathalmazt, így az onnan már bármikor gyorsan elérhetővé vált.

```
import pandas as pd
import numpy as np
from google.colab import drive
drive.mount('/content/drive/')
```

Beolvastuk az adathalmazt adf néven, ellenőrzésként kiírattuk az első 10 sorát:

```
import io
adf = pd.read_csv('/content/drive/My Drive/adatb.csv', error_bad_lines =
False, encoding='iso-8859-1', delimiter=";")
adf.head(10)
```

Tanító-, és teszthalmaz

A következőkben felbontottuk az adatainkat tanító-, illetve teszthalmazra. Ez a felosztás az összes modellünkre érvényes lesz.

```
from sklearn.model_selection import train_test_split
from sklearn.metrics import accuracy_score
y = adf.genre_top      #Y eset célváltozója
z = adf.genre          #Z eset célváltozója
x = adf.drop(['genre_top','genre','zcr.6'], axis=1)   #Magyarázóváltozó
x_train, x_test, y_train, y_test = train_test_split(x, y, test_size=0.3,
random_state=2)
x_train, x_test, z_train, z_test = train_test_split(x, z, test_size=0.3,
random_state=2)
np.asarray(x)
np.asarray(y)
np.asarray(z)
```

Megjegyzések:

- Hibajelzés után vettük észre, hogy a *zcr.6* oszlopunk hibás adatokat tartalmaz, így azt kidobtuk a magyarázóváltozókból.
- Y és Z esetnél is a teszthalmazunk 30%, így a tanulóhalmaz 70%.

Döntési fa

Elsőként döntési fát illesztettünk az adathalmazunkra a következő módon:

```
from sklearn import tree
model = tree.DecisionTreeClassifier()
model = model.fit(x_train, y_train)
y_test_model = model.predict(x_test)
print(accuracy_score(y_test, y_test_model))
model = model.fit(x_train, z_train)
z_test_model = model.predict(x_test)
print(accuracy_score(z_test, z_test_model))
```

Eredmények:

Lefuttatva a kódot, Y esetre 30%-ot, Z esetre 15%-ot kaptunk. Tehát a modell 30%-ban mondja meg jól, hogy milyen gyökérműfajú a zeneszám és 15%-ban mondja meg a pontos műfaját. Azt vártuk mi is, hogy az Y esetre jóval nagyobb %-ot kapunk, viszont összességében jobb eredményre számítottunk. Valószínűleg 16, illetve 163 db műfajba való helyes (vagy legalább 95%-os) besoroláshoz lényegesen nagyobb adathalmaz szükséges.

Mivel tudunk még javítani esetleg?

Először a *min_samples_leaf* tulajdonság értékének megadásával próbálkoztunk.
Ez a tulajdonság a levélcsomópontoknák szükséges minimális számú mintát adja meg.(Tehát csak akkor veszünk figyelembe egy pontot, ha az ágaiban minimum *min_samples_leaf* számú minta van.)
Megnéztük a következő értékekre: 20, 50, 100, 150, 170. Az ezekre kapott pontosságokból úgy tűnt, hogy 100 és 150 között lesznek valahol a legjobb eredmények, így készítettünk egy maximum kereső algoritmust, hogy megtudjuk melyik *min_samples_leaf*-nél kapjuk a legjobb eredményeket:

```
accy = 0
accz = 0
yi = 0
zi = 0

for i in range (100, 200, 10):
  model = tree.DecisionTreeClassifier(min_samples_leaf=i)
  model = model.fit(x_train, y_train)
  y_test_model = model.predict(x_test)
  if accuracy_score(y_test, y_test_model) > accy:
    accy = accuracy_score(y_test, y_test_model)
    yi = i
  model = model.fit(x_train, z_train)
  z_test_model = model.predict(x_test)
  if accuracy_score(z_test, z_test_model) > accz:
    accz =accuracy_score(z_test, z_test_model)
    zi = i

print(accy)
print(accz)
print(yi)
print(zi)

0.38438320209973753
0.23083989501312335
130
100
```

Tehát Y esetnél 38,44%-osan mondja meg jól a műfaját a számnak, 130-as minimális mintánál. A Z esetben 100 mintánál és 23,1%-os a pontosság.

További javítások érdekében a max_depth tulajdonságot is megadtuk többféle értéket kipróbálva, de ez nem hozott pozitív változást.

Ellenőrzés

A tanulóhalmazra tesztelve ellenőriztük, hogy jól működik- e a modell, és ahogy vártuk, 1-et kaptunk mindkét esetben.

```
model = tree.DecisionTreeClassifier()
model = model.fit(x_train, y_train)
y_train_model = model.predict(x_train)
print(accuracy_score(y_train, y_train_model))
model = model.fit(x_train, z_train)
z_train_model = model.predict(x_train)
print(accuracy_score(z_train, z_train_model))
1.0
1.0
```

kNN

Következő modellünknek a kNN-t választottuk.

kNN lényege: vesszük a teszt vektor *k* legközelebbi szomszédját a tanító halmazból. Amelyik osztálycímke legtöbbször fordul elő, azt rendeljük a tesztadathoz.

Kirajzoltattuk mindkét esetünkre, hogy a szomszédok számának változtatásával hogy változik a modell pontossága. (*weights='distance'* paranccsal a távolságot is figyelembe vettük)

```
from sklearn.neighbors import KNeighborsClassifier
import matplotlib.pyplot as plt
from sklearn.neighbors import KNeighborsClassifier
accs_y = []
accs_z = []
n_y = []
n_z = []
for i in range(1,100):
  knn_model = KNeighborsClassifier(n_neighbors=i, weights='distance')
  knn_model.fit(x_train, y_train)
  y_test_model = knn_model.predict(x_test)
  accs_y.append(accuracy_score(y_test, y_test_model))
  n_y.append(i)
  knn_model.fit(x_train, z_train)
  z_test_model = knn_model.predict(x_test)
  accs_z.append(accuracy_score(z_test, z_test_model))
  n_z.append(i)
plt.plot(n_y,accs_y)
plt.plot(n_z,accs_z)
```

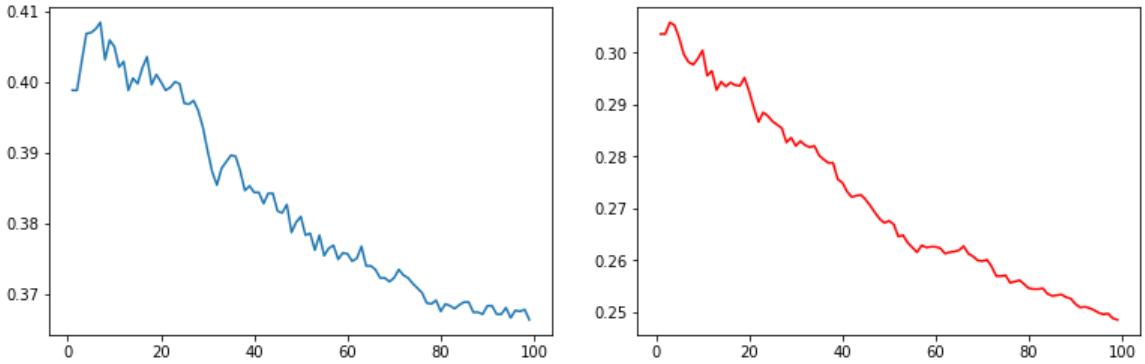

Látszik, hogy mindkét esetben a szomszédok növelésével csökken a teljesítmény. Y esetben kb 20 szomszédig a kNN jobban teljesít,mint a döntési fa, 40-41%-os pontosságot adva. A Z esetben pedig még 90-es szomszédszámnál is jobb a teljesítés, 25-30%-osra emelkedett a korábbi 23%-hoz képest.

Random Forest

Random Forestet futtattunk először 50 fával(*n_estimators = 50*), ettől a modelltől vártuk a legjobb eredményt.

```
from sklearn.ensemble import RandomForestClassifier
rfc = RandomForestClassifier(n_estimators=50, random_state=0)
rfc.fit(x_train, y_train)
y_test_model = rfc.predict(x_test)
print(accuracy_score(y_test, y_test_model))
rfc.fit(x_train, z_train)
z_test_model = rfc.predict(x_test)
print(accuracy_score(z_test, z_test_model))
```

A pontosság növekedett is, Y esetben közel 46%-ra, míg Z-nél 30%-ra.
n_estimator 150-es értékénél már Y 47%-os, Z pedig 31%.

DBSCAN

Végül a DBSCAN-t futtatunk az adathalmazunkra. Az eredményeket a

```
from sklearn import metrics
print("Silhouette Coefficient: %0.3f" % metrics.silhouette_score(x,labels))
```

segítségével ellenőriztük, ami `0.022`-t adott. Ez nagyon közel van 0-hoz, ami nagy átfedést jelent a klaszterek közt, emiatt ez nem egy jól használható módszer.

A beadandóval kapcsolatos gondolatok

Pozitív élmények:

Többször találkoztunk hárman (kétszer hétvégén is), hogy közösen dolgozzunk a beadandó feladaton, mindenki lásson minden lépést. Ezek nagyon jó hangulatban teltek, együtt próbálkoztunk és örültünk, ha valami (végre) sikerült.

Negatív élmények:

Mire egy használható adathalmazt kaptunk, nagyon sok idő elment. Így a modellek próbálgatására, „kísérletezésre”, vizuális ábrázolására már nagyon kevés maradt, így az elképzeléseinknél egyszerűbb beadandót sikerült csak készítenünk.